Agent Memory Graph

Propuesta de Producto y Despliegue para LATAM Airlines

Fecha de Generación: 2026-06-29

Autor: ADO — Analytics Data Office

Asunto: Plataforma Empresarial de Memoria para Agentes IA — Documento Interno

1. Resumen Ejecutivo

Agent Memory Graph (AMG) es una plataforma empresarial de coordinación de agentes IA, nativa en GCP, que resuelve los fallos más críticos de los despliegues de IA en producción: pérdida de contexto, alucinaciones y costo de inferencia descontrolado. Sus dos innovaciones principales — el pipeline de razonamiento MindMap y el sistema de Cognitive Weighting — trabajan en conjunto para entregar IA cualitativamente mejor: menor tasa de alucinación, recuperación más rápida y un consumo de tokens LLM significativamente menor en comparación con arquitecturas RAG convencionales.

El pipeline MindMap (inspirado en el artículo ACL'24 de Wen, Wang y Sun) obliga a que cada respuesta del agente sea construida exclusivamente a partir de evidencia recuperada del grafo. El sistema de Cognitive Weighting (inspirado en la infraestructura de memoria demostrable de Engram) asigna puntuaciones de confianza bayesianas a cada hecho en memoria, aplica decaimiento temporal al conocimiento obsoleto y condiciona la síntesis a umbrales de frescura y confianza. El resultado práctico: los agentes recuperan únicamente hechos recientes y de alta señal; los hechos no utilizados o contradictorios se desvanecen automáticamente; y el contexto del token se mantiene acotado y relevante, evitando las ventanas de contexto extensas y costosas propias del RAG ingenuo.

Para LATAM Airlines, AMG es la capa de coordinación que falta en la plataforma Cosmos: un tejido de memoria persistente y compartido en el que todos los agentes — desde copilotos internos de ingeniería hasta chatbots orientados a pasajeros — pueden confiar y razonar. AMG está listo para producción (v0.2, 843 pruebas pasando, P99 < 5ms), se despliega dentro de la organización GCP existente de LATAM e integra de manera natural con el Cosmos GenAI Gateway, DataHub y el catálogo Backstage.

> Cifras clave: Latencia P99 < 5ms (10x por debajo del SLO). El Cognitive Weighting acota el contexto de recuperación a solo los hechos de alta confianza, reduciendo directamente el gasto en tokens LLM por turno del agente. Tasa de fundamentación: 100% de las respuestas respaldadas por evidencia o señal explícita de insuficiencia (cero alucinaciones).

2. Descripción del Producto

Agent Memory Graph es un sistema de memoria determinista, con fundamentación prioritaria, para coordinar múltiples agentes IA dentro de una sola empresa. Elimina las alucinaciones al obligar a que cada respuesta del agente se derive de evidencia recuperada de una base de datos de grafos. Preserva el contexto organizacional a través de sesiones, usuarios y agentes. Y provee trazas de auditoría inmutables para cada paso de razonamiento, crítico para industrias reguladas y flujos de trabajo sensibles al cumplimiento normativo.

2.1 Los Problemas que Resuelve

Los despliegues de IA empresarial fallan por razones consistentes y bien comprendidas. AMG aborda cada una con una decisión arquitectónica específica, no con un parche temporal:

© 2026 LATAM Airlines

Problema	Cómo lo Resuelve AMG	Característica Clave
Pérdida de Contexto — los agentes olvidan interacciones entre sesiones; los usuarios deben re-explicar los mismos problemas repetidamente	El nivel Context almacena el historial completo de sesión; el nivel Semantic persiste hechos organizacionales indefinidamente; el recall es automático en cada turno del agente	Modelo de Memoria Tripartita
Alucinación — los agentes inventan hechos no fundamentados en datos organizacionales; las salidas no pueden ser confiables para decisiones operativas o reguladas	Pipeline MindMap: la síntesis está prohibida a menos que los hechos sean recuperados y serializados primero. Sin evidencia = señal explícita de insuficiencia, nunca una suposición	Pipeline de Fundamentación MindMap
Alto Costo en Tokens — el RAG ingenuo inunda el contexto del LLM con fragmentos débilmente relevantes, aumentando el gasto de inferencia a escala	El Cognitive Weighting filtra el grafo de recuperación a solo los hechos de alta confianza, frescos y de alta señal antes de la síntesis. Horizontes de traversal acotados previenen la dispersión de contexto	Cognitive Weighting (Bayesiano)
Baja Precisión de Recuperación — la búsqueda por similitud vectorial retorna fragmentos temáticamente similares pero factualmente poco confiables	El traversal del grafo sobre el nivel Semantic sigue relaciones tipadas entre entidades, produciendo caminos estructuralmente fundamentados, no vecinos vectoriales aproximados	Recuperación por Grafo Spanner
Brecha de Auditabilidad — sin trazas de razonamiento; imposible depurar decisiones o demostrar cumplimiento normativo	El nivel Audit registra cada acceso a memoria, llamada a herramienta, decisión de autorización y paso de razonamiento de forma inmutable (solo escritura, nunca eliminado)	Traza de Auditoría Inmutable
Fallos de Coordinación Multi-Agente — múltiples agentes toman decisiones contradictorias sin contexto compartido	Todos los agentes comparten el mismo grafo Semantic dentro de la organización. La detección de contradicciones señala hechos en conflicto antes de que lleguen a la síntesis	Memoria Org. Compartida + Detección de Contradicciones

2.2 Qué Ofrece AMG

- Modelo de Memoria Tripartita — Separación estricta de Context (historial de sesión específico del usuario), Semantic (hechos organizacionales duraderos con puntuación bayesiana de confianza) y Audit (registros inmutables de cumplimiento). Cada nivel tiene políticas independientes de retención, mutabilidad y acceso.
- Pipeline de Razonamiento MindMap — Un pipeline determinista de cuatro etapas: Mine → Aggregate → Serialize → Synthesize. Cada respuesta se construye exclusivamente a partir de evidencia recuperada del grafo. Si la evidencia es insuficiente, el sistema lo señala explícitamente — sin alucinación.
- Sistema de Cognitive Weighting — Pesos log-odds bayesianos en cada nodo y arista, decaimiento temporal para hechos obsoletos y condicionamiento de confianza y frescura en la síntesis. Solo los hechos relevantes, recientes y de alta señal llegan a la ventana de contexto del LLM, reduciendo el costo en tokens y mejorando la precisión.

© 2026 LATAM Airlines

- Coordinación Multi-Agente — Todos los agentes comparten el mismo grafo de memoria Semantic. Operaciones coordinadas y no redundantes. La detección de contradicciones expone hechos en conflicto antes de que influyan en una respuesta.
- Traza de Auditoría Inmutable — Cada acceso, llamada a herramienta y paso de razonamiento en el nivel Audit (solo escritura) para completa trazabilidad de cumplimiento y forense de incidentes.
- Gobernanza ABAC — Controles de autorización de grano fino que delimitan qué agentes pueden acceder a qué subgrafos, conjuntos de nodos y niveles. Denegación por defecto con códigos de razón auditados.
- Pipeline de Extracción de Documentos — Ingesta PDFs y archivos PowerPoint, extrae entidades, deduplica y puebla el grafo Semantic automáticamente, convirtiendo documentos institucionales en memoria organizacional consultable.

3. Descripción de la Arquitectura

AMG es un servicio Python nativo en GCP construido sobre FastAPI, desplegado en Cloud Run, respaldado por Google Cloud Spanner Graph para el almacén de memoria. Todos los componentes están contenerizados y gestionados mediante infraestructura como código Terraform. El sistema se despliega como un servicio dedicado de organización única dentro del proyecto GCP del cliente — ningún dato abandona el entorno del cliente.

3.1 Niveles de Memoria

AMG divide todo el conocimiento en tres niveles estrictamente aislados con diferentes políticas de retención, reglas de mutabilidad y controles de acceso. El diseño refleja la arquitectura de la memoria humana: memoria de trabajo (Context), memoria a largo plazo (Semantic) y registro autobiográfico (Audit).

Nivel	Alcance y Propietario	Qué Almacena	Actualizado Por	Ciclo de Vida
CONTEXT	Por usuario / por sesión	Turnos de conversación específicos del usuario, respuestas del agente, estado de sesión, razonamiento intermedio. Limitado estrictamente a una sesión y un usuario — sin intercambio entre usuarios.	Cada mensaje enviado o recibido, eventos de inicio/fin de sesión, llamadas a herramientas del agente durante un turno.	24–48 horas (decaimiento bayesiano rápido en sesiones inactivas)

© 2026 LATAM Airlines

Nivel	Alcance y Propietario	Qué Almacena	Actualizado Por	Ciclo de Vida
SEMANTIC	A nivel de organización	Hechos duraderos, relaciones entre entidades, insights descubiertos, conocimiento de documentos ingestados. Compartido entre todos los agentes de la organización dentro del alcance de la política ABAC.	Adición de hechos por agentes, pipeline de extracción de documentos, ingestión desde DataHub, inserciones manuales de conocimiento vía API.	Meses a años (decaimiento lento; refuerzo bayesiano en accesos repetidos)
AUDIT	Permanente / cumplimiento	Cada acceso a memoria, llamada a herramienta, concesión/denegación de autorización, paso de razonamiento y traza de orquestación. Indexado con códigos de razón.	Solo escritura — escrito por cada operación en todos los niveles. Nunca modificado ni eliminado.	Retención permanente

> Nota de privacidad: El nivel Context es el lugar adecuado para cualquier dato identificable del usuario en interacciones de agentes (IDs de pasajeros, IDs de empleados, contenido de sesión). Su decaimiento de 24-48h y el alcance estricto por sesión significan que los datos personales no se persisten indefinidamente — alineado con los principios de minimización de datos.

3.2 Pipeline de Razonamiento MindMap

El pipeline MindMap es el motor de razonamiento central de AMG. Está inspirado en el artículo de investigación "MindMap: Knowledge Graph Prompting Sparks Graph of Thoughts in Large Language Models" (Wen, Wang y Sun, ACL 2024 — github.com/wyl-willing/MindMap), que demostró que los LLMs fundamentados en evidencia de grafos de conocimiento producen respuestas estructuralmente coherentes y respaldadas por evidencia de manera mucho más confiable que la generación libre o el RAG ingenuo. AMG adapta estas ideas en un pipeline determinista, seguro para empresas y listo para producción.

El pipeline impone una disciplina estricta de evidencia: ningún LLM genera respuestas directamente a partir de la entrada del usuario. Cada respuesta pasa por cuatro etapas deterministas:

Etapa	Qué Hace	Salida
1. Mine	Extrae intención estructurada y entidades nombradas de la solicitud del agente. Identifica anclas de consulta para el traversal del grafo.	Lista de entidades + clasificación de intención

© 2026 LATAM Airlines

Etapa	Qué Hace	Salida
2. Aggregate	Recorre el Spanner Graph desde las anclas identificadas. La profundidad acotada del traversal y los umbrales de cognitive weight filtran caminos obsoletos o de baja confianza. Solo se accede a los subgrafos permitidos por ABAC.	Conjunto de caminos de evidencia (resultados de traversal tipado)
3. Serialize	Convierte caminos y aristas del grafo en payloads de hechos canónicos y trazables. Cada hecho recibe un ID único para su citación en la respuesta final. La procedencia (nodo fuente, tipo de arista, puntuación de confianza) se preserva.	Payload de hechos serializados con IDs de hechos
4. Synthesize	Genera la respuesta del agente ÚNICAMENTE a partir del payload de hechos serializados usando el LLM configurado (Cosmos GenAI Gateway). Se verifican las compuertas de frescura y confianza antes de la síntesis. Si no existen hechos o la confianza está por debajo del umbral, retorna una señal explícita de insuficiencia — nunca supone.	Respuesta fundamentada o insuficiencia explícita

> Validación de fundamentación: tras la síntesis, AMG verifica que cada afirmación en la respuesta referencie un ID de hecho presente en la evidencia serializada. Cualquier afirmación que referencie un ID de hecho desconocido provoca que la respuesta falle de forma segura — una garantía sólida contra la alucinación.

3.3 Sistema de Cognitive Weighting

El sistema de Cognitive Weighting le da a AMG su capacidad de ofrecer recuperación de alta precisión a bajo costo en tokens. Está inspirado en Engram — una infraestructura de memoria demostrable de código abierto para agentes IA (github.com/Harshitk-cp/engram) que alcanza el 91.4% en LongMemEval, el benchmark de ICLR 2025 para memoria conversacional a largo plazo. AMG adapta la intuición central de Engram — que los recuerdos deben ganar confianza cuando son reforzados, perderla cuando son contradichos y desvanecerse cuando no se usan — en un modelo de pesos log-odds bayesiano nativo al modelo de datos de Spanner Graph.

Cada nodo y arista en el grafo de memoria lleva un LogOddsWeight:

Mecanismo	Fórmula / Regla	Efecto
Peso inicial	LogOddsWeight = 0.5 (62% de confianza base)	Los nuevos hechos entran con confianza moderada — no se asume que son completamente confiables.

© 2026 LATAM Airlines

Mecanismo	Fórmula / Regla	Efecto
Refuerzo bayesiano	Weight += ln(1.25) ≈ +0.22 bits por acceso exitoso	Los hechos recuperados frecuentemente ganan confianza automáticamente. El conocimiento de alta señal sube al tope de los resultados de traversal.
Decaimiento temporal	Weight(t) = Weight(0) × e^(–0.05 × horas_desde_acceso)	Los hechos no utilizados se desvanecen. Un hecho con peso 2.73 tras uso intenso decae a casi cero después de una semana sin acceso — imitando el olvido.
Umbral de poda	Weight < 0.30 → eliminación suave del traversal activo	Los hechos obsoletos de baja confianza dejan de contaminar los resultados de recuperación sin una eliminación física definitiva.
Detección de contradicciones	En la ingestión, los hechos conflictivos se señalan con un marcador de tensión	La síntesis es condicional: los hechos contradictorios se presentan como ambiguos, no como autoritativos.
Compuerta de frescura	La síntesis verifica la frescura promedio del conjunto de evidencia contra el umbral de frescura configurado	Las respuestas señalan explícitamente cuando la evidencia es obsoleta — previniendo respuestas sobreconfiadas basadas en conocimiento desactualizado.

El impacto directo en el negocio de este sistema: en lugar de enviar cientos de fragmentos RAG débilmente relevantes al LLM, AMG envía únicamente los hechos de alta confianza, frescos y ponderados que pasaron todos los filtros. Esto acota la ventana de contexto de síntesis, reduce el consumo de tokens LLM por turno del agente y eleva la precisión de las respuestas — las dos palancas más importantes de costo y calidad para la IA empresarial a escala.

3.4 Endpoints Principales de la API

Endpoint	Método	Propósito
/health	GET	Sonda de disponibilidad y preparación para verificaciones de salud en Cloud Run
/api/v1/agent/respond	POST	Turno completo del agente con múltiples herramientas: orquesta recuperación de memoria, búsqueda en grafo, síntesis de evidencia y registro de trazas en una sola solicitud
/api/v1/mindmap/execute	POST	Ejecución directa del pipeline MindMap — Mine → Aggregate → Serialize → Synthesize
/api/v1/mcp/invoke	POST	Invocación de herramientas MCP: memory_search, memory_add_fact, memory_recall_context, memory_log_trace. Compatible con Claude Code, Codeen y el registro MCP del Cosmos GenAI Hub.

© 2026 LATAM Airlines

Endpoint	Método	Propósito
/internal/decay-weights	POST	Decaimiento programado de pesos cognitivos — reduce pesos de nodos/aristas inactivos
/internal/prune-weights	POST	Elimina evidencia de baja confianza con eliminación suave del nivel Semantic

3.5 Stack Tecnológico

Componente	Tecnología	Notas
Runtime	Python 3.14 / FastAPI	Verificación estricta de tipos (basedpyright, 0 errores, 0 advertencias)
Almacén de Memoria	Google Cloud Spanner Graph	Consultas ISO GQL, almacenamiento de aristas intercalado para traversal rápido
Despliegue	Cloud Run (contenerizado)	IaC con Terraform, estrategia de 3 entornos (dev/intg/prod)
Observabilidad	GCP Logging + Tracing + Metrics	Logs JSON estructurados, trazas OpenTelemetry, Cloud Monitoring
Autenticación y Gobernanza	ABAC Interno o Delegación Externa	Conectable: Okta, Auth0, Plataforma de Derechos o política interna
Backend LLM	Cosmos GenAI Gateway	Llama claude-sonnet-4-6, claude-opus-4-8, gemini-2.5-pro, gpt-5 según configuración
CI/CD	GitLab CI / Cloud Build	Pre-commit hooks, linting ruff, basedpyright, pytest — requeridos antes del merge
Pruebas	pytest — 843 pruebas, 100% pasando	Unitarias + Integración + Aislamiento cross-tenant + Escenarios de caos
Ingestión de Docs	Pipeline de extracción PDF/PPTX	Deduplicación difusa de entidades, puntuación de confianza, desplegado en Cloud Run

3.6 Modelo de Despliegue

AMG se despliega como un servicio dedicado de organización única dentro de la organización GCP del cliente. Todos los agentes de la organización comparten memoria dentro del mismo contexto de company_id. No hay multi-tenencia — los datos nunca se filtran entre organizaciones. El despliegue sigue una estrategia de tres entornos gestionados mediante workspaces de Terraform:

- Desarrollo — Pruebas de integración de agentes, conexión MCP, validación de esquema, incorporación del primer squad.
- Integración (INTG) — Ingeniería de caos, pruebas de carga (objetivo: 7.500+ req/seg), validación de aislamiento cross-tenant, revisión de documentación de cumplimiento.

© 2026 LATAM Airlines

- Producción — Despliegue canario (5% del tráfico) → monitoreo 24h → tráfico completo. Tiempo de rollback: < 5 minutos a la versión anterior.

Modo de Gobernanza	Descripción	Cuándo Usar
ABAC Interno (por defecto)	Políticas de autorización almacenadas en Spanner. Gestionado por LATAM. Sin dependencias externas.	Recomendado para el despliegue inicial y la mayoría de casos de uso
Delegación Externa	Las decisiones de autorización se delegan a un servicio de política externo mediante POST /authorize. Respuesta: permitir/denegar con código de razón.	Cuando LATAM desea sincronizar los permisos de AMG con una plataforma de identidad existente (ej. un servicio centralizado de derechos)

4. Valor Estratégico para LATAM Airlines

LATAM Airlines ya ha invertido significativamente en una plataforma moderna de IA y datos: el Cosmos GenAI Gateway (accediendo a Claude, GPT-5, Gemini y modelos Llama), DataHub para gobernanza de datos empresariales a través de dominios (CUSTOMER, MAINTENANCE, REFERENCE DATA, DATA INSIGHTS), Backstage para el catálogo de servicios y el Cosmos Feedback Engine para la mejora de la calidad de los chatbots. Agent Memory Graph es la capa de coordinación persistente que hace que estas inversiones se potencien: cada agente mejora la memoria compartida; cada squad se beneficia de lo que otros han aprendido.

4.1 El Ecosistema GenAI de LATAM Hoy

A través del Cosmos GenAI Gateway, LATAM opera una flota diversa de modelos servida desde Vertex AI y OpenAI: Claude Opus 4.8, Claude Sonnet 4.6, GPT-5, Gemini 3.1 Pro, Llama 4 Scout y más — con seguimiento de costo por usuario y controles de presupuesto. LATAM también ejecuta el Cosmos Feedback Engine, un sistema de mejora de calidad de chatbots de cuatro módulos (pipeline Dataflow, UI de revisión experta, gestor Cloud Run, liquidador diario) que ya enriquece las respuestas de chatbots con conocimiento validado por humanos. La plataforma demuestra una madurez de IA considerable.

Sin embargo, estos modelos son sin estado: cada llamada comienza desde cero, sin contexto compartido entre agentes, squads o sesiones. AMG aborda directamente esta brecha — es la capa de memoria persistente y compartida que transforma llamadas aisladas a modelos en flujos de trabajo de agentes coordinados, contextualizados y auditables.

4.2 Chatbots para Personal de LATAM y Clientes

Una de las aplicaciones de mayor impacto de AMG en LATAM es como columna vertebral de memoria para chatbots y asistentes IA que interactúan con dos audiencias distintas: el personal interno de LATAM y los pasajeros externos. Ambos segmentos tienen iniciativas de IA activas y problemas de memoria no resueltos.

4.2.1 Chatbots para Personal Interno

Los equipos ADO de LATAM, tripulaciones de operaciones, ingenieros de mantenimiento y agentes de contact center interactúan cada vez más con copilotos IA para búsqueda de conocimiento, guía de procesos

© 2026 LATAM Airlines

y apoyo a la toma de decisiones. Sin memoria persistente, estos agentes se reinician en cada sesión — obligando a los empleados a re-proveer contexto, re-explicar problemas en curso y redescubrir soluciones que otros agentes ya encontraron.

- Mantenimiento (MAPIS) — Los técnicos que consultan la base de conocimiento MAPIS (ya catalogada en BigQuery: emx-data-prod-e6c5.raw_emx_mapis_rag.mapis_knowledge_jan_26) se benefician de un copiloto IA que recuerda diagnósticos previos, sabe qué soluciones se aplicaron a fallos similares y cita sus fuentes para trazabilidad de seguridad crítica.
- Copilotos de Operaciones — Los agentes de gestión de disrupciones comparten un grafo Semantic común para que el hallazgo de un agente sobre la causa de un retraso informe inmediatamente a todos los demás agentes coordinadores — sin consultas redundantes ni decisiones contradictorias.
- Asistentes de Gobernanza de Datos — Los ingenieros ADO que interactúan con DataHub para revisión de propiedad de datasets, linaje y gestión de solicitudes de acceso obtienen un asistente con memoria que retiene el contexto del proyecto a través de semanas de trabajo sin necesidad de re-prompts.
- Copilotos de Ingeniería ADO — Los ingenieros incorporándose a nuevos datasets o pipelines obtienen un copiloto que recuerda qué han explorado, qué decisiones se tomaron y qué patrones existen — reduciendo significativamente el tiempo de incorporación.

4.2.2 Chatbots Orientados a Pasajeros

El dominio de experiencia del cliente de LATAM es uno de los más ricos en datos de la organización: encuestas NPS (digital, contact center y a bordo), tablas de voz del cliente e historiales de interacción ya están catalogados en DataHub bajo el dominio CUSTOMER (cus-data-prod.customer_experience.*). Estos datasets representan miles de interacciones diarias de pasajeros — una fuente valiosa para fundamentar la IA orientada a pasajeros.

AMG habilita una clase cualitativamente diferente de chatbot para pasajeros:

- Continuidad de sesión — Un pasajero que inicia una consulta de reserva, se desconecta y regresa horas después encuentra al agente aún con conocimiento de su itinerario, preferencias y pasos previos — no una pizarra en blanco que requiere re-explicación.
- Consistencia entre canales — Un pasajero que llamó al contact center ayer y ahora chatea en la app encuentra el mismo contexto. El nivel Semantic compartido (con alcance por entidad de pasajero) conecta canales sin requerir una consulta al CRM en cada turno.
- Respuestas fundamentadas y confiables — Las reglas tarifarias, políticas de equipaje y estados de vuelo se recuperan de evidencia fundamentada en el grafo — sin alucinaciones a partir de datos de entrenamiento que pueden estar desactualizados meses.
- Traza de auditoría lista para cumplimiento — Cada interacción de pasajero se registra en el nivel Audit. Para quejas reguladas, solicitudes de acceso de sujetos de datos o investigaciones de calidad, LATAM dispone de una traza de razonamiento completa e inmutable para cada decisión del chatbot.
- Integración de señal NPS — Las tablas NPS y de voz del cliente de DataHub pueden alimentar el nivel Semantic: los agentes que saben que un pasajero tuvo una mala experiencia reciente pueden adaptar su tono y umbral de escalación — una capa de personalización fundamentada en datos de comportamiento real.

© 2026 LATAM Airlines

> Sinergia con el Cosmos Feedback Engine: el nivel Semantic de AMG es el almacén ideal a largo plazo para los pares P/R validados que el Feedback Engine produce diariamente. En lugar de solo actualizar una base de datos vectorial en Cloud SQL, las respuestas validadas pueden ingestarse en el grafo Semantic de AMG — haciéndolas disponibles para todos los agentes a nivel organizacional, no solo para el chatbot para el que se construyó el Feedback Engine.

4.3 Casos de Uso de Alto Impacto en los Dominios de LATAM

Dominio	Caso de Uso	Capacidad AMG Utilizada	Impacto en el Negocio
Experiencia del Cliente	Chatbot multi-sesión para pasajeros con contexto persistente a través de app, web y canales de contact center	Nivel Context (por pasajero), hechos Semantic entre canales, ingestión de datos NPS	Menor tiempo de atención, mayor resolución en el primer contacto, UX consistente entre canales
Gestión de Ingresos	Agentes que consultan reglas tarifarias, datos de mercado y política de precios sin reingestar conocimiento en cada llamada	Nivel Semantic, fundamentación MindMap, priorización por cognitive weight	Ciclos de análisis más rápidos, cero reglas tarifarias alucinadas en decisiones automatizadas
Mantenimiento (MRO)	Copiloto IA para técnicos que acceden al conocimiento MAPIS con trazabilidad de seguridad crítica para cada recomendación	Pipeline de extracción de documentos (PDFs MAPIS), nivel Audit, validación de fundamentación	Recomendaciones IA listas para cumplimiento con traza de auditoría completa
Gobernanza de Datos	Asistente integrado con DataHub con contexto persistente sobre propiedad de datasets, linaje, historial de acceso y estado de gobernanza	Nivel Semantic (entidades DataHub), gobernanza ABAC, nivel Audit	Gestión de gobernanza automatizada con plena auditabilidad
Operaciones	Coordinación multi-agente para gestión de disrupciones — ningún agente actúa sobre información obsoleta o contradictoria	Grafo Semantic compartido, detección de contradicciones, contexto entre agentes	Decisiones operativas consistentes y no redundantes a escala
Copilotos Internos (ADO)	Asistentes IA para ingenieros y data scientists que recuerdan el contexto del proyecto, decisiones arquitectónicas y análisis previos a través de semanas	Niveles Context + Semantic, integración MCP con Claude Code / Codeen	Incorporación más rápida, eliminación de la sobrecarga de re-explicación de contexto

4.4 Alineación con la Infraestructura Existente de LATAM

- Nativo en GCP — Se despliega en la organización GCP de LATAM con los patrones de Cloud Run + Spanner + IAM ya establecidos en la plataforma Cosmos.

© 2026 LATAM Airlines

- Integración con Cosmos GenAI Gateway — La etapa Synthesize de AMG llama al GenAI Gateway como backend LLM. El acceso existente de LATAM a Claude/GPT/Gemini, el seguimiento de costos y los límites de tasa aplican.
- Soporte del Protocolo MCP — AMG expone una interfaz de herramientas compatible con MCP, compatible con Claude Code, Codeen y el registro MCP del Cosmos GenAI Hub. Regístrelo como Servidor MCP interno y todos los equipos de LATAM pueden descubrirlo y usarlo desde el catálogo Hub.
- Integración con DataHub — El pipeline de extracción de AMG puede ingestar activos catalogados en DataHub, enriqueciendo el nivel Semantic con metadatos de propiedad, linaje y calidad de datasets.
- Catálogo Backstage — AMG incluye un catalog-info.yaml que lo hace inmediatamente registrable como componente Backstage en el catálogo de servicios Cosmos.
- Cosmos Feedback Engine — Los pares P/R validados del Feedback Engine pueden fluir hacia el nivel Semantic de AMG, haciendo el conocimiento validado por expertos disponible para todos los agentes.

4.5 El Efecto Multiplicador Organizacional

El valor compuesto de AMG crece a medida que más agentes y squads lo adoptan. Hoy cada iniciativa de IA en LATAM opera de forma aislada — un chatbot de mantenimiento no sabe nada de lo que un agente de ingresos descubrió la semana pasada. AMG crea un grafo de conocimiento organizacional compartido donde los hallazgos de cada agente enriquecen el corpus para todos los agentes futuros. El cognitive weighting asegura que los hechos más frecuentemente útiles asciendan automáticamente al tope, mientras que el conocimiento no utilizado o contradicho decae — de modo que la memoria compartida se auto-mantiene sin curación manual.

> Alineación con cumplimiento normativo: LATAM opera en entornos regulados — seguridad aérea, reportes financieros, protección de datos de pasajeros. El nivel AUDIT inmutable de AMG y los controles ABAC proveen la trazabilidad y gobernanza de acceso requeridas para el uso de IA en decisiones de seguridad crítica y sensibles al cumplimiento. Ningún stack simple de RAG o chat sin estado provee esto.

5. Plan de Desarrollo y Despliegue para LATAM

AMG v0.2 está listo para producción. El plan de despliegue para LATAM se centra en integración, adopción y escalado — no en construir desde cero. El siguiente plan se estructura en cuatro fases a lo largo de aproximadamente 16 semanas.

5.1 Equipo Requerido

Rol	Cantidad	Responsabilidad	Fuente Sugerida
Ingeniero de Plataforma (GCP)	1 FTE	Terraform, Cloud Run, Spanner, IAM, CI/CD, monitoreo	Cosmos Platform Engineering

© 2026 LATAM Airlines

Rol	Cantidad	Responsabilidad	Fuente Sugerida
Ingeniero Backend (Python)	1–2 FTE	Integración de API, conexión con GenAI Gateway, conector Feedback Engine, adaptadores del pipeline de extracción	Squad GenAI (GENAI) o capítulo ADO
Ingeniero de Datos / IA	1 FTE	Diseño de esquema de entidades, estrategia de población del grafo Semantic, conectores DataHub y MAPIS	Capítulo Data & AI (cualquier squad)
Seguridad / Gobernanza	0.5 FTE	Diseño de políticas ABAC, auditoría IAM, documentación de cumplimiento, confirmación de residencia de datos	Seguridad de la Información / Habilitadores de Gobernanza ADO
Product Manager / Líder	0.5 FTE	Coordinación del squad piloto, seguimiento de KPIs, alineación con stakeholders, requisitos del chatbot de clientes	Líder de Capítulo (squad GENAI o jefe de capítulo ADO)
QA / Integración	0.5 FTE	Pruebas end-to-end, ingeniería de caos, validación de aislamiento cross-tenant	Dentro de cualquiera de los squads anteriores

Total: aproximadamente 4.5–5.5 FTE a lo largo de 16 semanas. Un piloto reducido (1 caso de uso, 1 squad) puede comenzar con 3 FTE en la Fase 1.

5.2 Presupuesto Estimado

Categoría	Ítem	Est. Mensual (USD)	Notas
Infraestructura	Cloud Run (2 instancias, autoescalado)	$150–400/mes	Escala con el volumen de solicitudes
Infraestructura	Cloud Spanner (1 nodo, ~10k RU/día)	$365/mes	Escala horizontalmente; 1 nodo maneja cientos de req/seg
Infraestructura	Cloud Build / pipeline CI	$50–100/mes	Según la frecuencia de builds
Infraestructura	GCP Logging + Monitoring + Tracing	$50–200/mes	Depende del volumen de logs y la retención
Inferencia LLM	Cosmos GenAI Gateway (etapa Synthesis)	Presupuesto existente	Claude Sonnet 4.6: ~$0.003/1k tokens de entrada vía gateway
Ingeniería	Equipo de plataforma (4.5 FTE × 16 semanas)	Único ~$120–180k	Aprovecha ingenieros internos; sin licencias de vendor

© 2026 LATAM Airlines

Categoría	Ítem	Est. Mensual (USD)	Notas
	TOTAL INFRAESTRUCTURA (mensual, estado estable post go-live)	~$615–1.100/mes	

> Nota de costos: A escala piloto (< 1k req/día), una instancia fraccionada de Spanner reduce la infraestructura a ~$100–200/mes. El Cognitive Weighting acota el contexto LLM por solicitud, manteniendo el costo de inferencia predecible a escala.

5.3 Fases y Cronograma

Fase 1 — Fundación y Piloto (Semanas 1–4)

Objetivo: Desplegar AMG en el entorno dev de GCP de LATAM y validar el pipeline central de memoria con un caso de uso real (recomendado: chatbot de mantenimiento MAPIS o asistente de gobernanza DataHub).

Semana	Actividad	Responsable	Entregable
1	Configuración GCP: Spanner, Cloud Run, IAM, workspaces Terraform, alertas de monitoreo	Ingeniero de Plataforma	Entorno dev en funcionamiento
1–2	Conexión del Cosmos GenAI Gateway a la etapa Synthesize de AMG; prueba de humo de respuesta fundamentada end-to-end	Ingeniero Backend	Pipeline completo retornando respuesta fundamentada
2	Registro catalog-info.yaml en Backstage; registro MCP en GenAI Hub	Ingeniero de Plataforma	AMG visible en Cosmos Backstage + descubrible desde Claude Code / Codeen
2–3	Incorporación del primer squad piloto — squad GenAI con un caso de uso; 50+ interacciones de agentes en dev	Product Lead + Backend	Piloto validado en dev
4	Revisión Fase 1: calidad de fundamentación, latencia P99, costo en tokens vs. línea base	Todos	Decisión Go/No-Go para Fase 2

Fase 2 — Integración y Enriquecimiento de Datos (Semanas 5–9)

Objetivo: Enriquecer el grafo Semantic con datos organizacionales de LATAM, integrar DataHub y el Feedback Engine, y expandir a 2–3 squads piloto incluyendo un chatbot orientado a pasajeros.

© 2026 LATAM Airlines

Semana	Actividad	Responsable	Entregable
5–6	Conector DataHub: ingestar metadatos de datasets, propiedad y linaje en el nivel Semantic	Ingeniero de Datos/IA	Entidades DataHub consultables desde AMG
6–7	Pipeline de extracción de documentos para MAPIS y bases de conocimiento internas de LATAM	Backend + Ingeniero de Datos	Primer corpus de conocimiento ingestado y ponderado
7	Conector Cosmos Feedback Engine: pares P/R validados fluyen al nivel Semantic	Ingeniero Backend	Conocimiento del Feedback Engine disponible para todos los agentes
7–8	Diseño de políticas ABAC alineado con el modelo IAM/identidad de LATAM	Seguridad / Gobernanza	Documento de política de autorización aprobado
8–9	Expansión a 2–3 squads: piloto de chatbot de experiencia del cliente + un squad interno	Product Lead	Piloto multi-squad en vivo con caso de uso orientado a pasajeros
9	Revisión Fase 2: cobertura de datos, cumplimiento de autorizaciones, coordinación entre squads	Todos	Aprobación para Fase 3

Fase 3 — Hardening y Producción (Semanas 10–14)

Objetivo: Desplegar en INTG y PROD, completar la documentación de cumplimiento y certificar para casos de uso de seguridad crítica y regulados.

Semana	Actividad	Responsable	Entregable
10–11	Despliegue INTG: ingeniería de caos, pruebas de carga (7.500+ req/seg), validación de aislamiento cross-tenant, prueba de integración de datos NPS	Plataforma + QA	Entorno INTG validado
11–12	Documentación de cumplimiento: revisión de traza de auditoría, auditoría de políticas ABAC, confirmación de residencia de datos de pasajeros, verificación de alineación GDPR/PDPA	Seguridad / Gobernanza	Documento de aprobación de cumplimiento
12–13	Despliegue canario en PROD (5% del tráfico) → monitoreo 24h → tráfico completo	Ingeniero de Plataforma	Entorno PROD en funcionamiento

© 2026 LATAM Airlines

Semana	Actividad	Responsable	Entregable
13–14	Runbook, procedimientos de escalación, configuración on-call, dashboard de SLO en Cloud Monitoring	Plataforma + Producto	Runbook operativo publicado
14	Revisión Fase 3: disponibilidad, completitud de auditoría, calidad del chatbot de pasajeros	Todos	Aprobación para producción

Fase 4 — Escala y Expansión (Semanas 15–16+)

- Incorporar todos los squads interesados del Capítulo Data & AI con documentación de autoservicio y grafos de conocimiento de dominio pre-cargados (mantenimiento, ingresos, experiencia del cliente).
- Expandir el chatbot de pasajeros a canales adicionales (app, web, contact center) usando el nivel Context + Semantic compartido para continuidad entre canales.
- Evaluar la publicación de AMG como componente reutilizable de la plataforma Cosmos, disponible para todos los squads de productos de LATAM a través del catálogo Backstage.
- Definir el roadmap v0.3: recuperación basada en embeddings, búsqueda vectorial sobre el nivel Semantic, plantillas de flujos de trabajo agénticos y señales de personalización impulsadas por NPS.

5.4 Registro de Riesgos

Riesgo	Probabilidad	Impacto	Mitigación
Demoras en cuota de Cloud Spanner	Baja	Medio	Solicitar aumento de cuota al inicio de la Fase 1; el emulador de Spanner está disponible para desarrollo local de inmediato
Requisitos de privacidad de datos de pasajeros (GDPR/PDPA)	Media	Alto	El nivel Context tiene decaimiento de 24-48h; sin PII persistente en el nivel Semantic por política; los controles ABAC gestionan el acceso; revisión legal en Fase 3
Complejidad creciente de políticas ABAC	Media	Bajo	Comenzar con denegación por defecto para todos los agentes y luego otorgar acceso de forma incremental — no al revés. Mantener las políticas declarativas.

© 2026 LATAM Airlines

Riesgo	Probabilidad	Impacto	Mitigación
Calidad de datos del grafo Semantic (basura entra, basura sale)	Media	Alto	Usar puntuaciones de calidad de DataHub para condicionar la ingestión; el pipeline de extracción incluye deduplicación difusa y puntuación de confianza
Sobrecosto LLM a escala del chatbot de pasajeros	Baja	Medio	El cognitive weighting acota el contexto por solicitud; el Cosmos Gateway provee seguimiento de presupuesto por usuario y límites estrictos
Disponibilidad del equipo (equipo reducido)	Alta	Medio	La Fase 1 puede ejecutarse con 3 FTE; AMG ya está construido — no se necesita I+D central. Acotar el alcance del piloto antes de escalar el equipo

6. Métricas de Éxito

Métrica	Objetivo	Medición
Tasa de Fundamentación	100% de respuestas respaldadas por evidencia o insuficiencia explícita	Nivel Audit: flag de fundamentación por respuesta
Tasa de Alucinación	0% (ninguna afirmación no respaldada pasa la compuerta de validación de fundamentación)	Verificación automática de fundamentación en etapa de síntesis + revisión de auditoría selectiva
Reducción de Costo en Tokens	>30% de reducción vs. RAG de línea base por turno del agente	Logs de tokens por turno del Cosmos Gateway antes vs. después de adopción de AMG
Latencia P99	< 50ms end-to-end (línea base medida actual: < 5ms)	Métricas de percentil de Cloud Monitoring
Disponibilidad	99.9% de uptime	Verificaciones de salud Cloud Run + alerta de uptime en Cloud Monitoring
Cobertura de Auditoría	100% de decisiones de autorización registradas con código de razón	Consulta al nivel Audit: eventos concedidos/denegados por día
Adopción de Agentes	5+ squads de LATAM usando AMG al final de la Fase 4	Conteo de invocaciones MCP por squad vía logs del GenAI Gateway
Calidad del Chatbot de Pasajeros	Mejora de NPS ≥ 5 puntos vs. línea base de chatbot sin estado	Tablas NPS de DataHub (cus-data-prod.customer_experience_analysis.nps_*)
Costo por Solicitud	< $0.01 por turno del agente (infraestructura + LLM)	Logs de costos del Gateway + métricas de uso de Spanner combinados

© 2026 LATAM Airlines

7. Recomendación y Próximos Pasos

Agent Memory Graph está listo para producción hoy. El enfoque recomendado para LATAM es comenzar con un piloto enfocado de 4 semanas liderado por el squad GenAI en un único caso de uso de alto valor y bien delimitado — ya sea el asistente de conocimiento de mantenimiento MAPIS o el copiloto de gobernanza DataHub. Ambos tienen fuentes de datos claras ya catalogadas, métricas de calidad claras y limitadas implicaciones de privacidad de datos de pasajeros, haciéndolos ideales para una primera validación antes de expandirse a chatbots orientados a clientes externos.

- Semana 1: El ingeniero de plataforma despliega el entorno dev en GCP; el GenAI Gateway se conecta con AMG.
- Semana 2: El squad GenAI ejecuta las primeras interacciones de agentes a través del pipeline MindMap; se valida la fundamentación y la completitud de la traza de auditoría.
- Semana 3: El stakeholder de seguridad/gobernanza revisa la configuración ABAC y los logs de auditoría.
- Semana 4: Decisión Go/No-Go. Si supera los umbrales → proceder al plan completo de 16 semanas. Si no → identificar la causa raíz e iterar antes de expandir.

El caso de uso del chatbot orientado a pasajeros — la aplicación de mayor escala e impacto — debe entrar al plan en la Fase 2, una vez que el piloto interno haya validado el pipeline central y el modelo de gobernanza. Esta secuencia gestiona el riesgo preservando el cronograma para la entrega de valor orientado al cliente.

> Punto de contacto sugerido: squad GenAI (Squad Lead: claudio.urbina@latam.com), en coordinación con el Capítulo Data & AI Ops (Chapter Head: grp_llmops_team@latam.com). Para alineación de gobernanza: Habilitadores de Gobernanza ADO (juanjose.gutierrezt@latam.com). Para requisitos del chatbot de pasajeros: Capítulo Data & AI Passenger (ATO-ATW).

© 2026 LATAM Airlines