Agent Memory Graph

La capa de memoria persistente para la IA empresarial de LATAM

Cosmos GenAI | DataHub | GCP-Native | v0.2 — Producción

EL DESAFÍO

Los agentes IA de LATAM operan sin memoria

Pérdida de Contexto

Cada sesión comienza desde cero. Pasajeros y empleados re-explican los mismos problemas repetidamente.

Alucinaciones

Los agentes inventan tarifas, políticas y datos. Las respuestas no son confiables para decisiones operativas.

Costo Impredecible

El RAG convencional inunda el contexto del LLM con información irrelevante, disparando el costo de inferencia.

Sin Trazabilidad

Imposible auditar las decisiones de los agentes. Riesgo de cumplimiento normativo en industrias reguladas.

LA SOLUCIÓN

Una capa de memoria compartida para todos los agentes



Memoria Persistente

Contexto de sesión, hechos organizacionales y auditoría inmutable. Todo separado y siempre disponible.



0% Alucinación

Cada respuesta se construye exclusivamente desde evidencia recuperada del grafo. Sin suposiciones.



Costo Controlado

El Cognitive Weighting filtra el contexto a solo los hechos relevantes. Tokens acotados, menor gasto.

RENDIMIENTO PROBADO

Listo para producción desde el primer día

LATENCIA P99	TASA DE FUND.	AHORRO TOKENS	PRUEBAS
< 5ms	**100%**	**>30%**	**843**
10× debajo del SLO	Cero alucinaciones	vs. RAG estándar	100% pasando

Benchmark externo: Engram (inspiración de Cognitive Weighting) alcanza el **91.4%** en LongMemEval — ICLR 2025

POR QUÉ AHORA

LATAM tiene la plataforma. Falta la memoria.

HOY — INVERSIÓN EXISTENTE

- ✓ Cosmos GenAI Gateway (Claude, GPT-5, Gemini, Llama)
- ✓ DataHub — gobernanza de datos empresarial
- ✓ Backstage — catálogo de servicios y componentes
- ✓ Cosmos Feedback Engine — calidad de chatbots

EL ESLABÓN FALTANTE

Todos estos modelos son **sin estado**: cada llamada comienza desde cero, sin contexto compartido entre agentes, squads o sesiones.

AMG es la capa que convierte llamadas aisladas en agentes que aprenden, coordinan y recuerdan.

APLICACIONES

Dos audiencias, un mismo tejido de memoria

Personal Interno

- → Técnicos de mantenimiento (MAPIS) con copiloto que recuerda diagnósticos previos
- → Gestión de disrupciones coordinada entre múltiples agentes
- → Ingenieros ADO con contexto de proyecto persistente entre semanas

Pasajeros y Clientes

- → Continuidad de sesión entre app, web y contact center
- → Respuestas fundamentadas en reglas tarifarias reales, no inventadas
- → Señal NPS integrada para personalización basada en experiencias previas

Meta de calidad: **NPS +5 puntos** vs. chatbot sin memoria · Datos disponibles en DataHub: `cus-data-prod.customer_experience.*`

VALOR COMPUESTO

Cada agente mejora el conocimiento de todos

Mantenimiento
MAPIS + histórico de fallas

Operaciones
Disrupciones coordinadas

Experiencia Cliente
Chatbots omnicanal

Gobernanza de Datos
DataHub integrado



El conocimiento de un squad **inmediatamente beneficia** a todos los demás. El Cognitive Weighting hace que los hechos más útiles suban solos.

INVERSIÓN

16 semanas · 4.5 FTE · Infraestructura predecible

FASES

- **F1 1-4w** — Fundación y Piloto — Deploy en dev + primer squad validado
- **F2 5-9w** — Integración — DataHub + Feedback Engine + chatbot de clientes
- **F3 10-14w** — Hardening — INTG + PROD + cumplimiento normativo
- **F4 15w+** — Escala — todos los squads ADO + expansión omnicanal

INVERSIÓN ESTIMADA

Ingeniería interna (4.5 FTE · 16w)	**$120–180k**
Infraestructura GCP (mensual)	**$615–1.100/mes**
Inferencia LLM	**Presupuesto existente**
Ahorro esperado en tokens	**>30% por turno**

PLAN DE ACCIÓN

Piloto de 4 semanas para validar el valor

S1

Deploy GCP dev

Cloud Run + Spanner + GenAI Gateway conectado

S2

Primeras interacciones

Squad GenAI valida pipeline MindMap y trazas de auditoría

S3

Revisión Seguridad

Auditoría ABAC + revisión de logs de cumplimiento

S4

Go/No-Go

Evaluación de KPIs → aprobación para despliegue completo

Contacto recomendado: **claudio.urbina@latam.com** (Squad Lead GenAI) · **grp_llmops_team@latam.com** (Chapter Head) · Gobernanza: **juanjose.gutierrezt@latam.com**

LISTO PARA PRODUCCIÓN · V0.2

LATAM merece agentes IA que aprendan y recuerden.

Agent Memory Graph transforma la inversión existente en la plataforma Cosmos en un sistema de IA que mejora con cada interacción.

0% Alucinación | **>30% ahorro en tokens** | **P99 < 5ms** | **100% auditable**