Agent Memory Graph

La capa de memoria persistente para la IA empresarial de LATAM

Cosmos GenAI | DataHub | GCP-Native | v0.2 — Producción

HISTORIA REAL · COLD START PROBLEM

El lunes de Martín Díaz, Data Engineer del squad ADO

Sin AMG — cada sesión comienza desde cero

Martín construye un agente de gobernanza sobre DataHub para responder: ¿quién es dueño de cada dataset? Para usarlo, abre una nueva sesión con el Cosmos GenAI Gateway.

- → Nueva sesión: el agente no recuerda nada del squad
- → 3 intercambios · 4.200 tokens · 45 min solo para re-establecer contexto
- → El agente responde: *"owner: Squad de Plataforma"* — interpoló de un dataset con nombre similar
- → Martín provisiona el acceso. Seguridad revierte: el owner real era Squad de Pricing

45 min · 4.200 tokens · 1 decisión incorrecta · rollback de seguridad

Con AMG — contexto desde el primer mensaje

- ✓ El grafo recuerda 12 hechos de alta señal del squad: datasets, owners, linaje
- ✓ Respuesta directa y verificada: *"owner: Squad de Pricing — fact_id #f-2291"*
- ✓ 1.200 tokens · audit trail completo · 0 rollbacks
- ✓ Martín provisiona el acceso correcto desde el primer intento

71% menos tokens · owner correcto · decisión trazable · sin rollback

El cold start ocurre en cada sesión de cada agente en LATAM hoy.
AMG lo elimina con un grafo de memoria persistente.

EL DESAFÍO

Los agentes IA de LATAM operan sin memoria

Pérdida de Contexto

Cada sesión comienza desde cero. Pasajeros y empleados re-explican los mismos problemas repetidamente.

Alucinaciones

Los agentes pueden inventar tarifas, políticas y datos. Las respuestas no son confiables para decisiones operativas.

Costo Impredecible

El RAG convencional inunda el contexto del LLM con información irrelevante, disparando el costo de inferencia.

Sin Trazabilidad

Imposible auditar las decisiones de los agentes. Riesgo de cumplimiento normativo en industrias reguladas.

LA SOLUCIÓN

Una capa de memoria compartida para todos los agentes

Memoria Persistente

Contexto de sesión, hechos organizacionales y auditoría inmutable. Todo separado y siempre disponible.

~ 0% Alucinación

Cada respuesta se construye exclusivamente desde evidencia recuperada del grafo. Sin suposiciones.

Costo Controlado

El Cognitive Weighting filtra el contexto a solo los hechos relevantes. Tokens acotados, menor gasto.

RENDIMIENTO PROBADO

Listo para producción desde el primer día

LATENCIA P99	TASA DE FUND.	AHORRO TOKENS	PRUEBAS
< 5ms	**100%**	**>30%**	**843**
10× debajo del SLO	Cero alucinaciones	vs. RAG estándar	100% pasadas

Benchmark externo: Engram (inspiración de Cognitive Weighting) alcanza el **91.4%** en LongMemEval — ICLR 2025

POR QUÉ AHORA

LATAM tiene la plataforma. Falta la memoria.

HOY — INVERSIÓN EXISTENTE

- ✓ Cosmos GenAI Gateway (Claude, GPT-5, Gemini, Llama)
- ✓ DataHub — gobernanza de datos empresarial
- ✓ Backstage — catálogo de servicios y componentes
- ✓ Cosmos Feedback Engine — calidad de chatbots

EL ESLABÓN FALTANTE

Todos estos modelos son **sin estado**: cada llamada comienza desde cero, sin contexto compartido entre agentes, squads o sesiones.

AMG es la capa que convierte llamadas aisladas en agentes que aprenden, coordinan y recuerdan.

APLICACIONES

Dos audiencias, un mismo tejido de memoria

Personal Interno

- → Técnicos de mantenimiento (MAPIS) con copiloto que recuerda diagnósticos previos
- → Gestión de disrupciones coordinada entre múltiples agentes
- → Ingenieros ADO con contexto de proyecto persistente entre semanas

Pasajeros y Clientes

- → Continuidad de sesión entre app, web y contact center
- → Respuestas fundamentadas en reglas tarifarias reales, no inventadas
- → Señal NPS integrada para personalización basada en experiencias previas

Meta de calidad: **NPS +5 puntos** vs. chatbot sin memoria · Datos disponibles en DataHub: `cus-data-prod.customer_experience.*`

RETORNO SOBRE LA INVERSIÓN

ROI estimado: >400% a 3 años · Break-even en mes 8

TCO AÑO 1 — INVERSIÓN INICIAL

Ingeniería interna (4.5 FTE · 16 sem.)	~$150.000
Infraestructura GCP año 1 (~$850/mes)	~$10.200
Total TCO Año 1	**~$160.000**

BENEFICIOS ANUALES (AÑO 2+)

Ahorro tokens LLM (>30%)	~$45.000/año
Productividad ingenieros (5 squads)	~$75.000/año
Calidad decisiones (0% alucinación)	~$100.000/año
Retención clientes (NPS +5 pts)	~$200.000/año
Total retorno anual	**~$420.000/año**

Mes 8
Break-even (conservador)

>400%
ROI a 3 años

$0
Licencias de software adicionales

REQUERIMIENTOS

Qué necesitamos del equipo LATAM para arrancar

Equipo — 4.5 FTE

- 1 Platform Engineer (GCP/Terraform)
- 1–2 Backend Python (APIs, conectores)
- 1 Data/AI Engineer (grafo, DataHub)
- 0.5 Seguridad/Gobernanza (ABAC)
- 0.5 Product Lead (piloto, KPIs)

Piloto Fase 1: mínimo 3 FTE

Tiempo de Otros Equipos

- Cosmos GenAI Gateway: **1h** (API key + budget)
- DataHub: **2h** (token de lectura + schema)
- Network/Cloud Platform: **1 día** (VPC connector)
- Seguridad/CISO: **2 días** (semanas 11–12)
- Legal/Compliance: **1 sem.** (solo si uso externo)

Accesos y Recursos GCP

- Proyecto GCP con Spanner · Cloud Run · Cloud Tasks · Cloud Build APIs
- Service account: `spanner.databaseAdmin` · `run.admin` · `iam.serviceAccountAdmin`
- Cosmos GenAI Gateway API key + límite de presupuesto
- DataHub read token · MAPIS BigQuery read
- GitLab write + Backstage catalog write

AMG v0.2 ya está construido. **No hay I+D pendiente** — solo integración, configuración y despliegue en tu GCP.

INVERSIÓN

16 semanas · 4.5 FTE · Infraestructura predecible

FASES

- **F1 1-4w** — Fundación y Piloto — Deploy en dev + primer squad validado
- **F2 5-9w** — Integración — DataHub + Feedback Engine + chatbot de clientes
- **F3 10-14w** — Hardening — INTG + PROD + cumplimiento normativo
- **F4 15w+** — Escala — todos los squads ADO + expansión omnicanal

INVERSIÓN ESTIMADA

Ingeniería interna (4.5 FTE · 16w)	**$120–180k**
Infraestructura GCP (mensual)	**$615–1.100/mes**
Inferencia LLM	**Presupuesto existente**
Ahorro esperado en tokens	**>30% por turno**

PLAN DE ACCIÓN

Piloto de 4 semanas para validar el valor

S1

Deploy GCP dev

Cloud Run + Spanner + GenAI Gateway conectado

S2

Primeras interacciones

Squad GenAI valida pipeline MindMap y trazas de auditoría

S3

Revisión Seguridad

Auditoría ABAC + revisión de logs de cumplimiento

S4

Go/No-Go

Evaluación de KPIs → aprobación para despliegue completo

Contacto recomendado: **claudio.urbina@latam.com** (Squad Lead GenAI) · **grp_llmops_team@latam.com** (Chapter Head) · Gobernanza: **juanjose.gutierrezt@latam.com**

LISTO PARA PRODUCCIÓN · V0.2

LATAM merece agentes IA que aprendan y recuerden.

Agent Memory Graph transforma la inversión existente en la plataforma Cosmos en un sistema de IA que mejora con cada interacción.

- 0% Alucinación
- >30% ahorro en tokens
- ROI >400% a 3 años
- 100% auditable