PROPUESTA TÉCNICA DE PRODUCTO

Agent Memory Graph

Arquitectura · Integración · Plan de Despliegue para LATAM

MindMap Pipeline | Cognitive Weighting | Spanner Graph · Cloud Run | MCP · ABAC · v0.2

PROBLEMA

Los modelos sin estado no son suficientes a escala

RAG Ingenuo

Inunda el contexto del LLM con chunks irrelevantes. Costo de tokens disparado. Precisión baja por similitud vectorial sin estructura.

Sin Coordinación

Agentes múltiples sin contexto compartido. Consultas redundantes, decisiones contradictorias, sin resolución de conflictos.

Sin Auditabilidad

Sin trazas de razonamiento. Imposible depurar, reproducir o demostrar cumplimiento para decisiones de agentes en producción.

AMG resuelve los tres con un modelo de memoria tripartita, un pipeline determinista de razonamiento y pesos cognitivos bayesianos.

ARQUITECTURA

Modelo de Memoria Tripartita

CONTEXT

Alcance: Por usuario / sesión

→ Turnos de conversación específicos del usuario

→ Estado de sesión e historial de agente

→ Actualizado por mensajes y eventos de sesión

→ Decaimiento: **24–48h**

SEMANTIC

Alcance: Organización completa

→ Hechos duraderos y relaciones entre entidades

→ Conocimiento de documentos ingestados

→ Compartido entre todos los agentes (ABAC)

→ Retención: **meses–años**

AUDIT

Alcance: Permanente / Cumplimiento

→ Cada acceso, autorización, llamada a herramienta

→ Solo escritura — nunca modificado ni eliminado

→ Indexado con códigos de razón

→ Retención: **permanente**

Las escrituras y lecturas **nunca cruzan niveles** en una sola transacción. Aislamiento estricto por diseño.

PIPELINE DE RAZONAMIENTO

MindMap: Determinista de 4 etapas (ACL 2024 · Wen, Wang & Sun)

1. MINE

Extracción

Entidades nombradas + intención de la solicitud del agente. Anclas para traversal del grafo.

2. AGGREGATE

Traversal

Recorre Spanner Graph con profundidad acotada. Filtra por cognitive weight y política ABAC.

3. SERIALIZE

Serialización

Caminos del grafo → payload de hechos con IDs únicos + procedencia completa.

4. SYNTHESIZE

Síntesis

LLM genera respuesta SOLO desde el payload. Sin evidencia → señal explícita de insuficiencia. Nunca supone.

Validación post-síntesis: cada afirmación debe referenciar un ID de hecho en el payload. Si no → falla segura. **Garantía de 0% alucinación.**

COGNITIVE WEIGHTING

Pesos log-odds bayesianos (inspirado en Engram · 91.4% LongMemEval)

$W_0 = 0.5$	Peso inicial (62% de confianza). Nuevos hechos entran con confianza moderada.
$W \mathrel{+}= \ln(1.25)$	+0.22 bits por acceso exitoso. Los hechos más usados ganan confianza automáticamente.
$W(t) \times e^{-0.05t}$	Decaimiento temporal. Hechos no usados se desvanecen. Olvido controlado.
$W < 0.30 \rightarrow \text{prune}$	Eliminación suave de evidencia de baja confianza. Sin contaminar el traversal.

Detección de Contradicciones

En ingestión, hechos conflictivos se señalan con marcador de tensión. Síntesis condicional: ambiguo, no autoritativo.

Impacto en Negocio

→ Contexto del LLM acotado a hechos de alta señal

→ >30% reducción de tokens vs. RAG estándar

→ Mayor precisión de respuesta sin costo adicional

INTEGRACIÓN

Nativo en el ecosistema Cosmos · LATAM

Cosmos GenAI Gateway

La etapa Synthesize llama al Gateway como backend LLM. Acceso a Claude Opus 4.8, Sonnet 4.6, GPT-5, Gemini. Control de presupuesto existente aplica.

`genai.cosmos.appslatam.com`

DataHub

Pipeline de extracción ingesta metadatos de DataHub (propiedad, linaje, calidad de datasets) al nivel Semantic. Activos CUSTOMER + MAINTENANCE disponibles.

`cus-data-prod.customer_experience.*`

Backstage + MCP

AMG incluye `catalog-info.yaml` para registro en Backstage. Expone interfaz MCP compatible con Claude Code, Codeen y GenAI Hub registry.

`tools: memory_search · memory_add_fact`

Cosmos Feedback Engine: Los pares P/R validados del Feedback Engine pueden fluir al nivel Semantic de AMG — disponibles para todos los agentes, no solo para el chatbot original.

CALIDAD Y RENDIMIENTO

Métricas de producción validadas

LATENCIA P99

< 5ms

SLO: < 50ms

THROUGHPUT

7.5k

req/seg objetivo

PRUEBAS

843

100% pasando

TIPOS ERRORES

0

basedpyright strict

Cobertura de docstrings	93.6%
Linting (ruff)	100% limpio
Tasa de fundamentación	100%
Ahorro tokens vs. RAG	> 30%

CASOS DE USO

Personal interno: ADO, Ops y Mantenimiento

Copiloto MAPIS (Mantenimiento)

Técnicos consultan la base de conocimiento MAPIS (`emx-data-prod-e6c5.raw_emx_mapis_rag.*`). El copiloto recuerda diagnósticos previos y cita fuentes para trazabilidad de seguridad crítica.

Coordinación de Disrupciones

Agentes de gestión de disrupciones comparten grafo Semantic común. Hallazgo de un agente sobre causa de retraso disponible para todos inmediatamente. Sin consultas redundantes.

Asistente de Gobernanza DataHub

Ingenieros ADO con contexto persistente sobre propiedad de datasets, linaje y estado de gobernanza a través de semanas de trabajo sin re-prompts.

Copiloto ADO vía MCP

Registrado en GenAI Hub → accesible desde Claude Code y Codeen sin configuración adicional. Cualquier squad ADO puede descubrirlo desde el catálogo Backstage.

CASOS DE USO

Pasajeros y clientes: omnicanal con memoria

Continuidad de sesión

Pasajero que abandona una consulta y regresa horas después encuentra al agente con el mismo contexto. Nivel Context: por pasajero, 24-48h.

Cross-canal (app → web → contact center)

Grafo Semantic con alcance por entidad de pasajero. Sin consulta a CRM en cada turno. Consistencia garantizada.

Respuestas fundamentadas

Reglas tarifarias y estados de vuelo desde evidencia del grafo. Sin alucinaciones sobre políticas de equipaje o cambios de itinerario.

Integración NPS → Personalización

Tablas NPS de DataHub como señal de personalización: agentes que conocen la experiencia previa del pasajero adaptan tono y umbral de escalación.

`customer_experience_analysis.nps_*`

Meta de calidad

NPS +5 pts

vs. chatbot sin memoria actual

STACK Y GOBERNANZA

GCP-native · ABAC · Terraform

COMPONENTES CORE

Runtime	`Python 3.14 / FastAPI`
Almacén de Memoria	`Cloud Spanner Graph (ISO GQL)`
Despliegue	`Cloud Run · Terraform IaC`
Observabilidad	`GCP Logging + OTel Tracing`

GOBERNANZA Y SEGURIDAD

ABAC Interno (por defecto)

Políticas en Spanner. Denegación por defecto. Códigos de razón para cada decisión. Sin dependencias externas.

Delegación Externa (opcional)

POST /authorize a servicio de política externo. Permite sincronización con plataforma de identidad LATAM (Okta, Auth0).

3 entornos · Terraform

dev / intg / prod. Canary 5% → 24h monitoreo → tráfico completo. Rollback < 5 min.

ROI Y TCO

Retorno sobre la inversión en USD · Break-even mes 8

TCO AÑO 1 — INVERSIÓN TOTAL

Ingeniería (4.5 FTE · 16 semanas)	~$150.000
Infra GCP año 1 (~$850/mes)	~$10.200
TOTAL TCO Año 1	**~$160.000**

Mes 8
Break-even

>400%
ROI a 3 años

BENEFICIOS ANUALES AÑO 2+ (ESTIMADO)

Ahorro tokens LLM (>30%)	~$45k
Productividad ingenieros (5 squads)	~$75k
Calidad / 0% alucinación en decisiones	~$100k
Retención clientes (NPS +5 pts)	~$200k
Total retorno anual estimado	**~$420k/año**

REQUERIMIENTOS

Qué necesita LATAM aportar para desplegar AMG

Equipo — 4.5 FTE

- 1 Platform Engineer (GCP · Terraform · CI/CD)
- 1–2 Backend Python (FastAPI · conectores)
- 1 Data/AI Engineer (grafo · DataHub · MAPIS)
- 0.5 Seguridad/Gobernanza (ABAC · compliance)
- 0.5 Product Lead (piloto · KPIs · stakeholders)
- 0.5 QA (integration · chaos testing)

Piloto Fase 1: mínimo 3 FTE

Tiempo de Otros Equipos

- Cosmos GenAI Gateway: **1h** — API key + límite presupuesto
- DataHub: **2h** — token de lectura + schema de tablas
- Network/Cloud Platform: **1 día** — VPC connector + allowlists
- Seguridad/CISO: **2 días** — revisión semanas 11–12
- Legal/Compliance: **1 semana** — solo uso externo (pasajeros)

Accesos y Permisos GCP

- Proyecto GCP (dev/intg/prod) con APIs: `Spanner` · `Cloud Run` · `Cloud Tasks` · `Cloud Build` · `Artifact Registry`
- Service account roles: `spanner.databaseAdmin` · `run.admin` · `iam.serviceAccountAdmin` · `logging.logWriter`
- MAPIS BigQuery: `emx-data-prod-e6c5.raw_emx_mapis_rag.*` read
- GitLab write repo · Backstage catalog write
- DataHub read token + presupuesto GenAI Gateway

AMG ya está construido. **No hay I+D pendiente.** El tiempo de otros equipos es puntual y acotado — ningún equipo necesita reasignar recursos permanentes.

PLAN DE DESPLIEGUE

16 semanas · 4.5 FTE · $615–1.100/mes infra

FASE 1 · S1–4

Fundación y Piloto

→ GCP dev + Spanner
→ GenAI Gateway conectado
→ 1er squad validado

FASE 2 · S5–9

Integración

→ DataHub + MAPIS
→ Feedback Engine
→ Chatbot de pasajeros

FASE 3 · S10–14

Hardening + PROD

→ INTG + chaos testing
→ Cumplimiento + ABAC
→ Canary → PROD

FASE 4 · S15+

Escala

→ Todos los squads ADO
→ Omnicanal pasajeros
→ Cosmos component

Equipo: 1 Platform Engineer (GCP) · 1–2 Backend Python · 1 Data/AI Engineer · 0.5 Seguridad/Gobernanza · 0.5 Product Lead · 0.5 QA · **Piloto mínimo: 3 FTE en Fase 1**

El grafo que recuerda lo que LATAM sabe.

AMG convierte los modelos sin estado del Cosmos Gateway en una red de agentes que comparten, aprenden y confían en la misma memoria organizacional.

0%	>30%	>400%	16 sem.
Alucinación	Ahorro tokens	ROI a 3 años	A producción

Primer paso: Piloto de 4 semanas con Squad GenAI · claudio.urbina@latam.com